

Zheng 等 - 2025 - DiffusionNFT 阅读笔记（算法重点版）

一、研究背景与核心问题

1.1 领域背景

在线强化学习（Online RL）已成为语言模型（LLMs）训练后优化的核心技术，能有效提升模型对齐性与推理能力，但在扩散模型（视觉生成领域主流模型）中的应用面临关键瓶颈：扩散模型的似然性无法精确计算，而传统 RL 算法（如 PPO、GRPO）高度依赖精确的模型似然来更新策略。

1.2 现有方法的缺陷

现有扩散 RL 方法（如 FlowGRPO）通过离散化反向采样过程（去噪过程）适配策略梯度框架，却存在三大不可忽视的缺陷，这也是 DiffusionNFT 需解决的核心问题：

- **正向 - 反向不一致**：仅聚焦反向去噪过程，脱离正向加噪过程的概率特性，导致模型可能退化为级联高斯分布，破坏扩散模型的核心数学基础（福克 - 普朗克方程）。
- **求解器绑定**：训练损失与一阶 SDE 求解器强耦合，无法利用更高效的 ODE 或高阶求解器，限制生成效率提升。
- **CFG 依赖复杂**：扩散模型常依赖无分类器引导（CFG）提升生成质量，但现有 RL 方法需同时训练条件与无条件模型，形成低效的双模型优化方案。
- **效率低下**：FlowGRPO 等方法需存储完整采样轨迹，且收敛速度慢，例如 GenEval 任务需 5k 步才能达到 0.95 分，还需额外依赖 CFG。

1.3 研究目标

提出一种全新的扩散 RL 范式，绕开反向过程与似然计算，直接在正向加噪过程上实现策略优化，同时解决求解器绑定、CFG 依赖与效率问题。

二、算法核心基础：前置概念与数学定义

在理解 DiffusionNFT 算法前，需明确其依赖的扩散模型与 RL 问题的核心定义，这是算法设计的数学基石。

2.1 扩散模型的正向过程与流匹配

2.1.1 正向加噪过程

扩散模型通过逐步向干净图像 x_0 （服从数据分布 $\pi_0 = p_{\text{data}}$ ）添加高斯噪声，生成时刻 t 的带噪样本 x_t ，其数学定义为（）：

$$x_t = \alpha_t x_0 + \sigma_t \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

其中 α_t （信号强度，随 t 减小）、 σ_t （噪声强度，随 t 增大）是预设的时间调度函数，转移核为 $\pi_{t|0}(x_t|x_0) = \mathcal{N}(x_t | \alpha_t x_0, \sigma_t^2 I)$ 。

2.1.2 速度参数化与流匹配

模型通过速度预测器 $v_{\theta}(x_t, t)$ 学习正向过程的轨迹切线方向，训练目标是 최소화 预测速度与目标速度的 MSE 损失 ()：

$$\mathcal{L}_{\text{flow}} = \mathbb{E}_{t, x_0, \epsilon} \left[w(t) \| v_{\theta}(x_t, t) - v \|_2^2 \right]$$

其中目标速度 $v = \dot{\alpha}_t x_0 + \dot{\sigma}_t \epsilon$ ($\dot{f} = df/dt$ 为时间导数)， $w(t)$ 是时间权重。此时反向采样可简化为 ODE： $\frac{dx_t}{dt} = v_{\theta}(x_t, t)$ ，即“流匹配”框架，欧拉离散化后等价于 DDIM 采样。

2.2 在线 RL 的问题设定

2.2.1 策略与奖励

- **初始策略**：预训练扩散策略 π^{old} ，对应速度预测器 v^{old} ；
- **数据采集**：对每个提示词 c ，采样 K 个干净图像 $x_0^{\{1:K\}}$ ，用奖励函数 $r(x_0, c) \in [0, 1]$ 评估图像最优性 ($r=1$ 表示完全符合需求， $r=0$ 表示完全不符合)；
- **正负分布定义**：基于奖励将采样数据划分为正分布 π^+ (高奖励) 与负分布 π^- (低奖励)，其数学表达式为 ()：

$$\pi^+(x_0|c) = \frac{r(x_0, c) \cdot \pi^{\text{old}}(x_0|c)}{p_{\pi^{\text{old}}}(o=1|c)}$$

$$\pi^-(x_0|c) = \frac{(1-r(x_0, c)) \cdot \pi^{\text{old}}(x_0|c)}{1-p_{\pi^{\text{old}}}(o=1|c)}$$

其中 $p_{\pi^{\text{old}}}(o=1|c)$ 是 π^{old} 生成最优图像的边际概率，且满足 $\pi^{\text{old}} = p_{\pi^{\text{old}}}(\pi^+ + (1-p_{\pi^{\text{old}}}(o=1|c))\pi^-)$ (引理 A.1)。

- **优化目标**：找到优化策略 π^* ，满足 $\mathbb{E}_{\pi^*} r(x_0, c) > \mathbb{E}_{\pi^{\text{old}}} r(x_0, c)$ (记为 $\pi^* \succ \pi^{\text{old}}$)。

三、DiffusionNFT 算法核心设计

DiffusionNFT (Diffusion Negative-aware FineTuning) 是一种“无似然、正向过程优化、基于监督学习的 RL 范式”，核心包括**改进方向定义**、**训练目标函数**、**关键实现细节**三部分。

3.1 核心 1：改进方向 Δ 的定义 (定理 3.1)

3.1.1 核心理想

由于 $\pi^+ \succ \pi^{\text{old}} \succ \pi^-$ ，策略改进的本质是“向 π^+ 靠拢、远离 π^- ”。DiffusionNFT 通过关联 π^+ 、 π^- 、 π^{old} 对应的速度预测器，定义一个隐含的改进方向 Δ ，确保基于 Δ 更新的策略满足 $\pi^* \succ \pi^{\text{old}}$ 。

3.1.2 关键前提：速度预测器与后验的关系

扩散模型的速度预测器 v 与数据后验均值 $\mathbb{E}[x_0|x_t, c]$ 存在线性关系：

$$v(x_t, c) = a_t x_t + b_t \cdot \mathbb{E}_{\pi(x_0|x_t, c)}[x_0]$$

其中 $a_t = \dot{\sigma}_t / \sigma_t$ 、 $b_t = \dot{\alpha}_t - (\dot{\sigma}_t \alpha_t) / \sigma_t$ ，仅与时间调度相关。这意味着：**不同分布的速度预测器差异，完全由其后验均值差异决定。**

3.1.3 后验分布的线性分解 (引理 A.2)

π^{old} 的后验分布可分解为 π^+ 与 π^- 后验的加权和：

$$\pi^{\text{old}}(x_0|x_t, c) = \alpha(x_t) \cdot \pi^+(x_0|x_t, c) + (1 - \alpha(x_t)) \cdot \pi^-(x_0|x_t, c)$$

其中权重 $\alpha(x_t) \in [0, 1]$ ，定义为：

$$\alpha(x_t) = \frac{\pi^+(x_t)}{\pi^+(x_t) + \pi^-(x_t)} \cdot \mathbb{E}_{\pi^{\text{old}}} r(x_0, c)$$

$\pi^+(x_t)$ 是 π^+ 在时刻 t 的边际分布。

3.1.4 Δ 的数学表达式

对后验分解等式取 $\mathbb{E}[x_0 \cdot]$ ，并代入速度预测器公式，整理得：

$$\Delta = \alpha(x_t) \cdot (v^+ - v^{\text{old}}) = (1 - \alpha(x_t)) \cdot (v^{\text{old}} - v^-)$$

其中 v^+ 、 v^- 分别是 π^+ 、 π^- 对应的速度预测器。

3.1.5 Δ 的物理意义

- Δ 是“向正策略优化、远离负策略”的量化方向： $\alpha(x_t)$ 大时，优先向 v^+ 学习； $\alpha(x_t)$ 小时，优先远离 v^- ；
- 若将 v^{old} 更新为 $v^* = v^{\text{old}} + \frac{1}{\beta} \Delta$ (β 为引导强度)，可确保 $\pi^* = \pi^+ \cdot \text{succ} \pi^{\text{old}}$ 。

3.2 核心 2：训练目标函数 (定理 3.2)

3.2.1 设计思路

DiffusionNFT 不直接优化 Δ ，而是通过**监督学习目标**，让模型自动逼近 $v^* = v^{\text{old}} + \frac{2}{\beta} \Delta$ 。为同时利用正负样本，定义“隐含正 / 负策略”，将 RL 目标转化为可优化的 MSE 损失。

3.2.2 隐含策略定义

- 隐含正策略**： $v_{\theta}^+ = (1 - \beta)v^{\text{old}} + \beta v_{\theta}$
含义： v_{θ} 与 v^{old} 的加权组合， β 越大， v_{θ}^+ 越接近 v_{θ} ，代表向 π^+ 倾斜的策略。
- 隐含负策略**： $v_{\theta}^- = (1 + \beta)v^{\text{old}} - \beta v_{\theta}$
含义： v_{θ} 对 v^{old} 的“反向修正”， β 越大， v_{θ}^- 与 v_{θ} 差异越大，代表远离 π^- 的策略。

3.2.3 目标函数公式

目标函数通过“正样本上优化隐含正策略、负样本上优化隐含负策略”实现 RL 改进，表达式为：

$$\mathcal{L}(\theta) = \mathbb{E}_{c, x_0 \sim p_i^{\text{old}}, t} \left[r \cdot |v_{\theta^+} - v|^2 + (1-r) \cdot |v_{\theta^-} - v|^2 \right]$$

其中：

- r 是权重：正样本（ r 大）优先最小化 v_{θ^+} 与 v 的误差，负样本（ r 小）优先最小化 v_{θ^-} 与 v 的误差；
- v 是正向过程的目标速度（ $\dot{\alpha}_t x_0 + \dot{\sigma}_t \epsilon$ ），确保训练与正向过程一致。

3.2.4 最优解证明

当数据量无限且模型容量足够时， $\mathcal{L}(\theta)$ 的最优解 v_{θ^*} 满足：

$$v_{\theta^*} = v^{\text{old}} + \frac{2}{\beta} \Delta$$

这表明：**通过最小化监督损失**，模型自动实现了基于**的策略改进，无需显式优化 RL 目标。**

3.3 核心 3：关键实现细节 (Algorithm 1)

DiffusionNFT 的工程实现需解决奖励归一化、策略更新、权重调整等问题，算法伪代码的核心步骤如下：

3.3.1 初始化

- 采样策略 v^{old} 与训练策略 v_{θ} 均初始化为预训练模型 v_{ref} ；
- 数据缓冲区 D 初始化为空。

3.3.2 数据采集 (Rollout Step)

1. 对每个采样的提示词 c ，用 v^{old} 采样 K 个干净图像 $x_0^{1:K}$ ；
2. 计算每个图像的原始奖励 r^{raw} ，并按组归一化： $r_{\text{norm}} = r^{\text{raw}} - \text{mean}(r^{\text{raw}}_{1:K})$ ；
3. 将 $\{c, x_0^{1:K}, r_{1:K}\}$ 存入缓冲区 D ，其中 r （最优性概率）通过下式转换为 $[0, 1]$ 区间：

$$r = 0.5 + 0.5 \cdot \text{clip}\left(\frac{r_{\text{norm}}}{Z_c}, -1, 1\right)$$

Z_c 是归一化因子（如全局奖励标准差）。

3.3.3 策略优化 (Gradient Step)

1. 从 D 中采样 mini-batch $\{c, x_0, r\}$ ；
2. 生成正向加噪样本 $x_t = \alpha_t x_0 + \sigma_t \epsilon$ ，计算目标速度 $v = \dot{\alpha}_t x_0 + \dot{\sigma}_t \epsilon$ ；
3. 计算隐含正 / 负策略： $v_{\theta^+} = (1-\beta)v^{\text{old}} + \beta v_{\theta}$ ， $v_{\theta^-} = (1+\beta)v^{\text{old}} - \beta v_{\theta}$ ；

4. 计算损失 $\mathcal{L}(\theta)$ ，并更新训练策略 v_θ ：

$$\theta \leftarrow \theta - \lambda \nabla_\theta \left[r | v_\theta^2 + -v |^2 + (1-r) | v_\theta^2 - v |^2 \right]$$

λ 是学习率。

3.3.4 采样策略更新 (Online Update)

采用“软更新”策略更新 v^{old} （避免硬更新导致的不稳定），公式为：

$$\theta^{\text{old}} \leftarrow \eta_i \theta^{\text{old}} + (1 - \eta_i) \theta$$

其中 η_i 是更新权重（随迭代次数 i 调整，初始小 η 加速收敛，后期大 η 保证稳定），更新后清空缓冲区 $\mathcal{D}$ 。

3.3.5 其他关键设计

- **自适应损失权重**：替换传统人工设计的 $w(t)$ ，采用基于 x_0 预测误差的自归一化权重：

$$\frac{|x_\theta - x_0|^2}{\text{sg}\left(\text{mean}\left(\text{abs}(x_\theta - x_0)\right)\right)}$$

$\text{sg}(\cdot)$ 是停止梯度算子，避免分母梯度影响权重计算，提升训练稳定性（图 9）；

- **CFG-free 优化**：初始化时仅用条件模型，不依赖 CFG，通过 RL 训练替代 CFG 功能，简化流程且性能超越 CFG 基线（图 1）；
- **求解器灵活性**：数据采集可使用任意黑箱求解器（ODE / 高阶 SDE），无需存储采样轨迹，仅需干净图像与奖励（图 2）。

四、算法性能验证：实验与结果

4.1 实验设置

- **基础模型**：SD3.5-Medium (2.5B 参数)，生成分辨率 512×512；
- **对比基线**：SD3.5-M (带 / 不带 CFG)、FlowGRPO、SD-XL (1024×1024)、SD3.5-L (8B)、FLUX.1-Dev (12B)；
- **奖励模型**：规则型 (GenEval、OCR)、模型型 (PickScore、ClipScore、HPSv2.1 等)；
- **训练配置**：LoRA ($\alpha=64$ ， $r=32$)，学习率 $3e-4$ ，每个 epoch 48 组，组大小 24。

4.2 核心实验结果

4.2.1 与 FlowGRPO 的效率对比 (图 1a、图 6)

- **效率优势**：DiffusionNFT 在 4 个单奖励任务中效率是 FlowGRPO 的 3-25 倍；
- **GenEval 任务**：DiffusionNFT 仅需 1k 步将分数从 0.24 提升至 0.98 (CFG-free)，而 FlowGRPO 需 5k 步且依赖 CFG 才能达到 0.95；

- **OCR 任务**：DiffusionNFT 在 250 GPU 小时内达到 0.38 分，FlowGRPO 需 1500 GPU 小时（24× 效率提升）（图 6b）。

4.2.2 多奖励联合训练（表 1）

在无 CFG 设置下，DiffusionNFT 优化的 SD3.5-M 表现优异：

- **规则型指标**：GenEval 0.94、OCR 0.91，远超带 CFG 的 SD3.5-M（0.63、0.59）；
- **模型型指标**：PickScore 23.80、ImageReward 1.49，超过 SD3.5-L（8B）、FLUX.1-Dev（12B）等更大模型；
- **泛化性**：在域外奖励（Aesthetic、UnifiedReward）上仍保持高性能，证明多任务适配能力。

4.2.3 消融实验：关键设计的必要性

- **负损失的重要性**：移除 v_{θ} 的损失后，训练立即崩溃，证明负样本信号对扩散 RL 至关重要（区别于 LLMs 的 RFT 方法）；
- **求解器影响**：ODE 求解器（尤其是二阶 ODE）采样质量优于 SDE，PickScore 指标提升更显著（图 7）；
- **软更新策略**：初始小 η （如 $\eta=0$ ）加速早期收敛，但易不稳定；后期大 η （如 $\eta=0.5$ ）保证稳定，最优策略是 $\eta_i = \min(0.001i, 0.5)$ （图 8）；
- **引导强度 β** ： $\beta=1$ 时训练最稳定， $\beta=0.1$ 可加速奖励提升（图 10）。

五、算法优势与局限

5.1 核心优势

1. **效率极高**：3-25 倍于 FlowGRPO，无需依赖 CFG，收敛速度快；
2. **灵活性强**：支持任意黑箱求解器，无需存储采样轨迹，工程实现简单；
3. **稳定性好**：正向过程一致性、自适应权重、软更新策略共同保证训练鲁棒性；
4. **泛化性优**：多奖励联合训练下，域内与域外任务均表现优异，超越更大模型；
5. **无似然依赖**：绕开扩散模型似然难计算的问题，避免系统偏差。

5.2 潜在局限

1. **超参数敏感**： β 、 η_i 等超参数需根据任务微调（如 OCR 任务需 $\eta_{\max}=0.999$ 稳定训练）；
2. **高分辨率适配**：实验仅验证 512×512 分辨率，1024×1024 等更高分辨率的性能待验证；
3. **视频生成扩展**：当前聚焦图像生成，视频等时序生成任务的适配需进一步研究。